A/B-forsøg med prisstrategier

Præregistrering, økonomisk effekt og én slutanalyse

Danhostel Aarhus City · Prismotor

Metodeversion 1 · 17. oktober 2026

Resumé

Dette dokument beskriver den implementerede forsøgsmetode. A er den normale prisstrategi, B er den fastlåste prismodel. V4 og V5 er varianter af samme model og er ikke kontrolstrategien. Formålet er at estimere effekten af at tildele en prisstrategi på faktisk dækningsbidrag pr. fysisk seng pr. nat. Et forsøg kræver prospektiv randomisering, dokumenteret anvendelse og afstemte resultater. Prognosepræcision og historiske korrelationer dokumenterer ikke denne effekt.

Indhold

1 Spørgsmålet og forsøgets grænser **2**

2 Præregistrering og tildeling **3**

3 Primært økonomisk mål **3**

4 Estimand og estimat **4**

5 Én primær test og et omtrentligt interval **4**

5.1 Randomiseringstest 4

5.2 Parret interval 5

5.3 Fortolkning og praktisk relevans 5

6 Styrke og varighed **6**

7 Drift, datakvalitet og låsning **6**

8 Hvad et positivt resultat kan sige **7**

Referencer **7**

1 Spørgsmålet og forsøgets grænser

Den videnskabelige inspiration er kontrollerede forsøg med en på forhånd valgt Overall Evaluation Criterion (OEC), som beskrevet af Kohavi m.fl. [1]. Papiret handler primært om værdien og kulturen omkring eksperimenter. Det foreskriver ikke dette hostels blokdesign eller den konkrete inferens. Det følgende er en lokal tilpasning; formlerne er beskrevet eksplicit.

Priser og kapacitet er fælles for gæsterne. Individuel lodtrækning pr. booking ville kunne skabe konkurrence mellem forsøgsarmene om samme lager. Derfor anvendes hele huset i blokke af *opholdsdatoer*. Det er ikke et skift af strategi for alle fremtidige datoer på én bestemt kalenderdag. Rumtyper og senge får samme arm på en opholdsdato. Flerdagesophold henføres økonomisk til hver opholdsdato.

Gæster kan stadig flytte mellem datoer; bookinger kan krydse blokgrænser. Randomisering fjerner ikke denne afsmitning. Betydelig afsmitning, ændrede kanalvilkår eller anden samtidig behandling hindrer en simpel kausal fortolkning. Bojinov m.fl. [3] viser netop, at carryover er et særskilt designproblem i switchback-forsøg. Vi implementerer ikke deres optimale design eller deres carryover-robuste estimator. Længere blokke kan mindske risikoen, men beviser ikke, at den er væk. Vurdér opholdslængde, bookinghorisont og datofleksibilitet før start; udfør først en driftsprøve med samme strategi i begge arme (A/A).

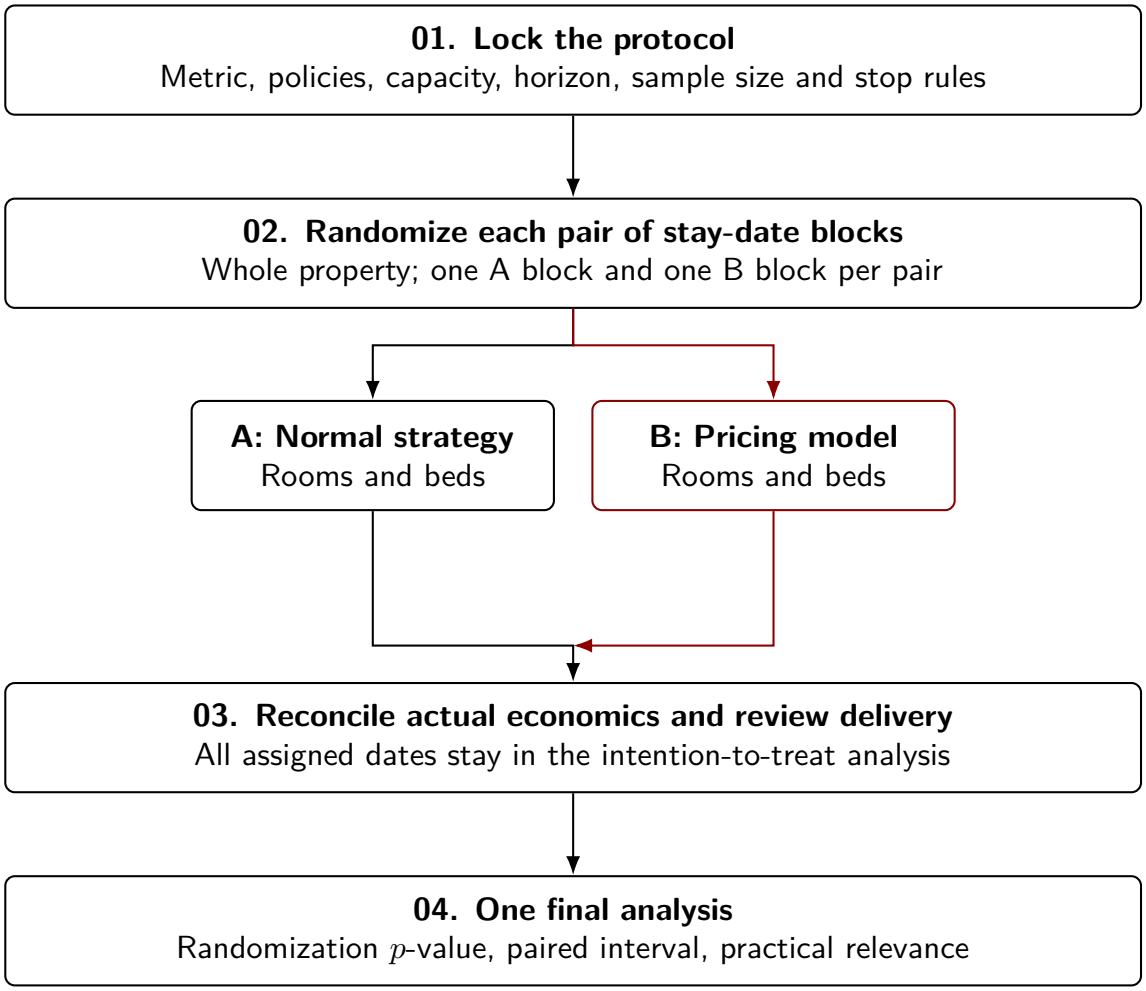


Figure 1: Fra låst protokol til låst resultat. Figuren viser designet, ikke indsamlede data.

2 Præregistrering og tildeling

Et par består af to på hinanden følgende lige lange blokke på $L \in \{7, 14, 28\}$ dage. Første blok starter mandag; ugedage er dermed repræsenteret ens i begge arme. Hvert af m par randomiseres uafhængigt med en fair mønt:

$$Z_j \sim \text{Bernoulli}(1/2), \qquad (T_{j1}, T_{j2}) = \begin{cases} (A, B) & Z_j = 0, \\ (B, A) & Z_j = 1. \end{cases} \tag{1}$$

Sæson og events er ikke identiske i to naboblokke. Randomisering håndterer dem i forventning; få ekstreme datoer kan give stor usikkerhed. Alle grupper, events og blokeringer indgår. Ingen datoer fjernes efter randomisering. Vil man afgrænse en anden population, kræver det et nyt, foruddefineret design.

Før tildeling låses navn, A-strategiens konkrete regler, første dato, m, L, fælles prisperiode H, fast fysisk kapacitet C, praktisk tærskel $\delta_\star$, planlægningsspredning σ_D, stopregler og vurdering af afsmitning. Prisen for hver opholdsdato styres efter sin arm fra H dage før datoen til ankomst. Første prisperiode skal begynde efter registreringsdagen. Allerede solgte ophold omprissættes ikke. Deres resultat indgår i intention-to-treat (ITT), hvilket kan fortynde effekten. Konklusionen gælder denne prisperiode og den valgte population.

Appen genererer en tilfældig seed, gemmer kalenderen og dens SHA-256-protokolhash. En seed gør tildelingen reproducerbar; den er ikke bevis for korrekt prislevering. Analysens kildekodehash og versionerne af NumPy og SciPy gemmes også. Ændringer af dem blokerer en bekræftende slutanalyse med en anden metode end den registrerede. Overlappende opholdsdatoer i registrerede forsøg afvises. Der er ingen redigering eller ny lodtrækning i brugerfladen. JSON-eksporten indeholder protokol og log.

B's indlæste modelparametre, det aktuelle efterspørgselsniveau og centrale kodefiler identificeres med hash. Den fælles online niveaulæring skal pauses før registrering: resultater fra tidligere blokke kan ellers ændre senere blokkes priser og skabe afsmitning via læringen. Teknisk kræves `pricing.v4.level_alpha: 0` og genindlæsning af konfigurationen. Forsøgssektionen ændrer ikke selv indstillingen. Dette forsøg måler den fastlåste politik; hele den adaptive politik kræver et andet design. Genestimering af grundmodellen og ændringer af algoritme eller parametre er en ny behandling. Nye markeds- og belægningsdata er tilladte input. Appen kontrollerer aktuel hash ved slutanalyse; det er ikke en automatisk kontrol af alle historiske tilstande. Blokgennemgangen skal dokumentere, at politikken var stabil under hele forsøget. Forsøget skifter ikke automatisk priser i Picasso.

3 Primært økonomisk mål

For hver afsluttet opholdsdato d anvendes:

$$G_d = R_d^{\text{rum}} + R_d^{\text{seng}} + a_d - Q_d - V_d, \tag{2}$$

$$Y_{jk} = \frac{\sum_{d \in B_{jk}} G_d}{LC}. \tag{3}$$

R er bogført logiomsætning eksklusive moms og morgenmad; a_d er et eventuelt ufordelt afstemt afrundingsbeløb; Q_d er faktisk provision og V_d faktisk variabel omkostning på samme nettogrundlag og opholdsdato. Ukendte omkostninger er manglende data, ikke nul. Modellens prisforslag er inklusive 25% moms og uden morgenmad; forslag indgår ikke som faktisk omsætning.

C er det før forsøget fastlåste antal fysiske senge for hele huset, inklusive senge i privatværelser. Det er ikke antal solgte senge, og flexkapacitet tælles ikke dobbelt. Kapaciteten skifter ikke

med B's allokering, belægning eller blokeringer. Målet er derfor bidrag pr. *fast fysisk seng pr. nat*, ikke det øvrige dashboards RevPAB med faktisk tilgængelig kapacitet. Permanent ændret kapacitet er et protokolbrud. Faste omkostninger indgår ikke; et højere bidrag er ikke det samme som et dokumenteret højere regnskabsmæssigt overskud.

4 Estimand og estimat

Lad $Y_{jk}(B)$ og $Y_{jk}(A)$ være de potentielle blokresultater uden afsmitning. Målet er den ligevægtede gennemsnitlige effekt over forsøgets $2m$ blokke:

$$\tau = \frac{1}{2m} \sum_{j=1}^{m} \sum_{k=1}^{2} \{Y_{jk}(B) - Y_{jk}(A)\}. \tag{4}$$

Hvert par leverer ét observeret bidragsestimat:

$$D_j = Y_{j,B}^{\text{obs}} - Y_{j,A}^{\text{obs}}, \qquad \widehat{\tau} = \bar{D} = \frac{1}{m} \sum_{j=1}^{m} D_j. \tag{5}$$

Randomiseringen gør estimatet unbiased for τ under konsistens og ingen afsmitning. Bookinger, prisberegninger og datoer inden for samme blok tæller ikke som uafhængige forsøg. Afvigelser fra tildelt strategi bevares i den oprindelige arm: ITT måler effekten af *tildeling*, ikke en separat effekt blandt dem, der faktisk fulgte strategien.

Den relative ændring vises deskriptivt som $100\widehat{\tau}/\bar{Y}_A$ når $\bar{Y}_A > 0$. Der gives ikke et separat konfidensinterval eller en separat test for procenten. Antal solgte værelser og senge vises hver for sig som sekundær beskrivelse uden nye hypotesetests.

5 Én primær test og et omtrentligt interval

5.1 Randomiseringstest

Den primære tosidede test anvender Fisher's *skarpe nulhypotese*: $H_0 : Y_{jk}(B) = Y_{jk}(A)$ for alle blokke. Det er stærkere end blot $\tau = 0$; resultatet er ikke en eksakt test af den svage nulhypotese ved heterogene effekter. Under den skarpe nulhypotese kan armene ombyttes uafhængigt i hvert par. Med $T_{\text{obs}} = |\sum_j D_j|$ fås

$$p_{\text{exact}} = 2^{-m} \sum_{\epsilon \in \{-1,+1\}^m} \mathbf{1}\left\{ \left| \sum_j \epsilon_j D_j \right| \geq T_{\text{obs}} \right\}. \tag{6}$$

Alle 2^m tildelinger gennemgås ved $m \leq 16$. Ved større m trækkes $M = 99\,999$ tildelinger med en særskilt på forhånd gemt seed:

$$p_{\text{MC}} = \frac{1 + \sum_{b=1}^{M} \mathbf{1}\{T_b \geq T_{\text{obs}}\}}{M + 1}. \tag{7}$$

Plus-én-korrektionen [4] undgår et kunstigt $p = 0$. Appen rapporterer metode og antal træk. Flydende tal sammenlignes med en lille numerisk tolerance. Ved $m = 6$ er mindste eksakte tosidede p omtrent $2/2^6 = 0.03125$; seks par er kun en teknisk nedre grænse og ingen garanti for styrke.

5.2 Parret interval

Spredning og standardfejl beregnes som hos NIST [2]:

$$s_D^2 = \frac{1}{m-1}\sum_j (D_j - \bar{D})^2, \qquad \widehat{\mathrm{SE}} = s_D/\sqrt{m}, \tag{8}$$

$$I_{.95} = \bar{D} \;\pm\; t_{.975,m-1}\, s_D/\sqrt{m}. \tag{9}$$

Intervallet er *omtrentligt*, baseret på uafhængige par og en rimelig normaltilnærmelse for pargennemsnittet; det er ikke inversion af randomiseringstesten. Tidsmæssig afhængighed på tværs af par, få par eller meget skæve/outlier-prægede bidrag kan gøre intervallet upålideligt. Ingen automatisk winsorisering eller fjernelse af outliers udføres. Ved observeret nulspredning vises intet interval, fordi et nulbredde-interval ville give falsk sikkerhed.

5.3 Fortolkning og praktisk relevans

$\alpha = 0.05$ er låst og tosidet. Appen markerer positiv evidens når primær $p \le 0.05$ *og* nedre omtrentlige intervalgrænse er over nul. En praktisk relevant forbedring markeres først når grænsen også overstiger den forudvalgte $\delta_\star$. Dette er en kombineret beslutningsregel, ikke en ny eksakt randomiseringstest mod $\delta_\star$. Et usikkert resultat betyder ikke ligeværdighed. p er ikke sandsynligheden for, at modellen er bedre.

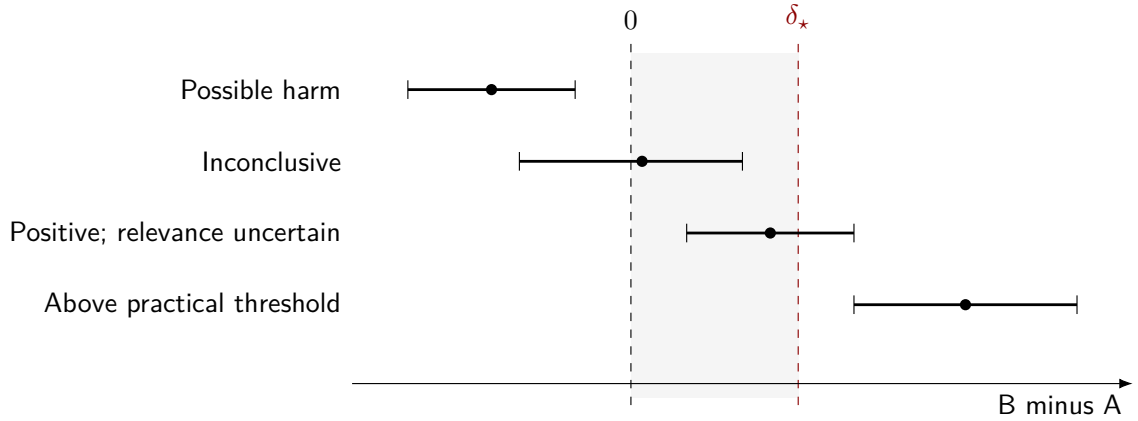


Figure 2: Illustrative intervaller; ingen af punkterne er faktiske forsøgsresultater.

6 Styrke og varighed

Det nødvendige antal par planlægges med en normaltilnærmelse:

$$m_{\text{plan}} = \max\left(6, \left\lceil \left[\frac{(z_{1-\alpha/2} + z_{1-\beta})\sigma_D}{\delta_\star} \right]^2 \right\rceil\right), \qquad 1-\beta = 0.80. \tag{10}$$

σ_D skal være spredningen af *forskelle mellem parrede blokke* i samme måleenhed som primærmålet. Det er ikke spredningen af daglig omsætning eller individuelle bookinger. Estimér den fra sammenlignelige, afstemte historiske økonomital eller en A/A-driftsprøve, og angiv begrundelsen i protokollen.

Eksempel: $\sigma_D = 6$ og $\delta_\star = 5$ kr. giver 12 par, altså 24 uger ved $L = 7$, plus mindst H dages forløb og tid til regnskabsafstemning. Tallene er illustrationer, ikke estimater fra hostellets data. Styrken er kun et skøn for et parret middeltestdesign; den garanterer ikke 80% styrke for den konkrete randomiseringstest, især ved få par eller heterogene/skæve effekter. Brug en forudgående designsimulation, hvis konklusionen kræver en præcis styrkegaranti. Appen kræver mindst det omtrentlige planlægningsantal, men erstatter ikke dette arbejde.

7 Drift, datakvalitet og låsning

1. Beskriv A konkret: prisregler, informationsgrundlag, beslutningstidspunkt og hvem der udfører dem. Hold kanaler, rabatter, minimumsophold, grupperegler og andre indgreb fælles, medmindre de udtrykkeligt er en del af behandlingen.
2. Hent kalenderen. Anvend A/B for hver opholdsdato i den aftalte prisperiode. Log anvendte priser og tidspunkt under Resultater. Gem bevis fra Picasso; en CSV-eksport eller godkendelse beviser ikke anvendelse.
3. Registrér nye bookinger, annulleringer, manuelle indgreb, grupper, blokeringer og events. Efter hver blok gemmes en driftsgennemgang med kilde og afsløring af afvigelser. Rettelser til gennemgangen gemmes som nye logposter.
4. Importér og bekræft afsluttede resultater pr. opholdsdato; afstem logi uden moms og morgenmad. Tilføj faktiske provisioner og variable omkostninger, inklusive oplyst nul. En senere registrering, der tilbagekalder endelig status, kan ikke ignoreres til fordel for en ældre komplet post.
5. Sluttest åbnes først, når alle planlagte datoer har fulde, bekræftede resultater og alle blokke er gennemgået. Manglende data må hverken nuludfyldes eller medføre selektiv fjernelse af par. Systemet viser datadækning undervejs, men ingen inferentielle delresultater.
6. Før afslutning attesteres fælles regnskabsgrundlag, stabil behandling, ingen væsentlig afsmitning og ingen selektion af datoer. Ved tvivl stoppes forsøget som ugyldigt/ufuldstændigt, uden en bekræftende test. En attest er operatørens vurdering og ikke et statistisk bevis for antagelserne.
7. Slutanalysen gemmer de præcise kildepost-ID'er, payloads, blokgennemgange, protokolhash, tidspunkt og ansvarlig. Senere rettelser i resultatloggen ændrer ikke dette snapshot. Fejl kræver en særskilt dokumenteret reanalyse, tydeligt mærket som sådan; brugerfladen tilbyder ikke gentagne bekræftende analyser.

Faste stopregler kan være prisfejl, gæsteklager, kapacitetsændring eller et på forhånd aftalt driftsmæssigt tabskriterium. Appen overvåger dem ikke automatisk; operatøren skal stoppe forsøget. En tidlig sikkerhedsstopning giver ingen bekræftende p-værdi. Gentagen test indtil signifikans er ikke tilladt i denne fast-horisont-metode. Eventuel sekventiel analyse kræver en ny metode/protokol.

Blokrandomiseringen garanterer præcis én A og én B pr. par. Et almindeligt binomialt 50/50-SRM-test er derfor ikke relevant for antal blokke. Kontrollér i stedet den gemte kalender, fuld datadækning og korrekt levering. Forskelle i bookingantal er mulige behandlingseffekter og ikke i sig selv en tildelingsfejl.

Der er ét primært mål og én bekræftende test pr. protokol. Sekundære opdelinger og procenttal er beskrivende. Gentagne eksperimenter på samme hypotese eller valg af det bedste blandt mange kræver en samlet multiplicitetsplan; appens enkelte protokol giver ikke automatisk kontrol af denne fejlrate.

8 Hvad et positivt resultat kan sige

Under designets antagelser giver et positivt resultat evidens for, at tildeling til B øgede bidraget i den testede population og prisperiode. Det estimerer ikke prisfølsomhed separat, garanterer ikke fremtidigt overskud og må ikke uden videre omregnes til en årsgevinst. Resultater fra andre sæsoner, politikændringer og større skala kræver opfølgning. Et A/A-forløb kontrollerer dataflow og drift; et ikke-signifikant A/A-resultat beviser ikke fejlfrihed.

Referencer

[1] Kohavi, R., Crook, T., Longbotham, R., Frasca, B., Henne, R., Lavista Ferres, J. og Melamed, T. (2009). *Online Experimentation at Microsoft.* Brugerens offentlige ThinkWeek-version, især afsnit 2. https://www.microsoft.com/en-us/research/publication/online-experimentation-at-microsoft/

[2] NIST/SEMATECH. *e-Handbook of Statistical Methods*, 7.3.1.1, Analysis of paired observations. https://www.itl.nist.gov/div898/handbook/prc/section3/prc311.htm

[3] Bojinov, I., Simchi-Levi, D. og Zhao, J. *Design and Analysis of Switchback Experiments.* arXiv:2009.00148. Bruges til at belyse afsmitning; deres estimator er ikke implementeret her. https://arxiv.org/abs/2009.00148

[4] Phipson, B. og Smyth, G. K. (2010). *Permutation P-values Should Never Be Zero: Calculating Exact P-values When Permutations Are Randomly Drawn.* Statistical Applications in Genetics and Molecular Biology, 9(1), Article 39. https://doi.org/10.2202/1544-6115.1585