

Matematikken bag v4

Efterspørgselsfordeling, prisvalg og værdien af kapacitet

Dokumenteret ud fra projektets reference og implementering, 3. oktober 2026.

1 Hvad optimerer modellen?

Version 4 vurderer hvert muligt pristrin ud fra det forventede bidrag fra *fremtidigt* salg. Den vælger ikke en pris for at ramme en bestemt målbelægning. For et lager og en opholdsdato er kerneproblemet

$$k^* = \arg \max_k \underbrace{((1-c)p_k - v)}_{\text{bidrag pr. solgt enhed}} \underbrace{\mathbb{E}[\min(X_k, C)]}_{\text{forventet fremtidigt salg}}. \quad (1)$$

Her er X_k den ikke-negative, heltallige efterspørgsel ved pris p_k , og C er ledig kapacitet. Allerede bogført omsætning ændres ikke ved at vælge en ny pris og indgår derfor ikke i denne optimering.

Koden kalder målet `expected_revenue`. Fordi både provision og variabel omkostning trækkes fra, er det mere præcist et **forventet dækningsbidrag** end bruttoomsætning. Der beregnes særskilt for private værelser og dormsenge.

Symbol	Betydning
t, ℓ	Opholdsdato og antal dage til opholdsdatoen (lead time).
B, C	Enheder på bøgerne (OTB) og resterende salgsbar kapacitet.
$Y_t, R_{t,\ell}$	Historisk endeligt salg og netto pickup: $R_{t,\ell} = Y_t - B_{t,\ell}$.
p_k, p_0	Pris på trin k og pris på referencetrinnet.
c, v	Provisionsandel og variabel omkostning pr. solgt enhed.
ε, L	Antaget priselasticitet og adaptivt efterspørgselsniveau.
μ, Z	Prognoseskala for pickup og empirisk formvariabel.
$S_D(x)$	Halesandsynlighed $\mathbb{P}(D \geq x)$ for resterende efterspørgsel.

Tre lag i beslutningen. Først estimeres efterspørgslen ved referenceprisen. Derefter beregnes økonomien på alle pristrin. Til sidst anvendes markedsjustering, events, træghed og prisgrænser. Den endelige pris behøver derfor ikke være det ubetingede optimum i (1).

Dette er en model af de resterende salg ved en given pris, ikke en fuld dynamisk optimering af alle fremtidige prisændringer, bookingforløb og ophold på én gang.

2 Fra reservationshistorik til efterspørgsel

Bookingkuben rekonstruerer $B_{t,\ell}$ ved hjælp af oprettelses- og annulleringsdatoer. Netto pickup kan være negativ, når annulleringerne overstiger nysalget. Flytninger og andre ændringer uden fuld ændringshistorik kan ikke rekonstrueres eksakt.

2.1 Sæson og gennemsnit

Lad $m(t)$ være måned og $w(t)$ ugedag. På de brugbare træningsdatoer estimeres

$$s_m = \frac{\text{gennemsnit}(Y_t \mid m(t) = m)}{\text{gennemsnit}(Y_t)}, \quad (2)$$

$$a_{\ell,w} = \text{gennemsnit} \left(\frac{R_{t,\ell}}{s_{m(t)}} \mid w(t) = w \right), \quad (3)$$

$$\mu_{t,\ell}^{\text{raw}} = \max\{0, a_{\ell,w(t)} s_{m(t)} L\}. \quad (4)$$

Sæsonfaktoren er dimensionsløs. $a_{\ell,w}$ og μ^{raw} måles i enheder. Udsolgte datoer flagges som censurerede og udelades som standard; særlige lukkeperioder kan også udelades. Det fjerner ikke censureringsproblemet: de udeladte datoer kan netop være dem med størst latent efterspørgsel.

2.2 Den empiriske form

For observationer med $a_{\ell,w} \geq 2$ beregnes forholdet

$$z_{t,\ell} = \frac{R_{t,\ell}}{s_{m(t)} a_{\ell,w(t)}}. \quad (5)$$

Disse forhold samles i lead-intervallerne

$$[0, 1], [2, 3], [4, 6], [7, 10], [11, 17], [18, 30], [31, 45], [46, 70], [71, 365].$$

Hvert interval gemmes som 201 empiriske kvantiler $q_0, \dots, q_{200}$. Det bevarer skævhed, gruppespring og negative observationer uden at vælge en Poisson-fordeling. Tomme intervaller låner en form fra et andet interval.

Mellem to forskellige nabokvantiler bruges lineær interpolation. Hvis $q_{i-1} < z \leq q_i$, er den implementerede hale

$$S_Z(z) = 1 - \frac{i - 1 + (z - q_{i-1})/(q_i - q_{i-1})}{200}. \quad (6)$$

Gentagne kvantiler håndteres særskilt i koden. Over højeste kvantil bruges en konstrueret hale, med $T = \max(q_{200}, 10^{-9})$:

$$S_Z(z) = \max \left\{ 10^{-4}, \frac{1}{201} \exp \left(-\frac{z - T}{\max(0, 25T, 10^{-9})} \right) \right\}. \quad (7)$$

Dette er en numerisk regularisering, ikke en estimeret ekstremhale. Gulvet og springet lige over største kvantil betyder, at funktionen ikke overalt er en matematisk konsistent overlevelseshale. Forventningsformlerne nedenfor er idealet; koden bruger denne numeriske approksimation.

3 Krympning mod kalendergennemsnittet

En stor tidlig gruppebooking er ikke nødvendigvis et pålideligt signal om det endelige salg. Derfor kombineres bøger plus pickup med et kalendergennemsnit $H_{w,m} = \text{gennemsnit}(Y_t \mid w, m)$:

$$\hat{Y}_{t,\ell} = w_\ell(B_{t,\ell} + \mu_{t,\ell}^{\text{raw}}) + (1 - w_\ell)H_{w(t),m(t)}L, \quad (8)$$

$$\mu_{t,\ell} = \max\{0, \hat{Y}_{t,\ell} - B_{t,\ell}\}. \quad (9)$$

$w_\ell = 1$ lægger al vægt på bøger plus pickup; $w_\ell = 0$ lægger al vægt på kalenderen. Bindingen `model.bind(otb)` gør det aktuelle B tilgængeligt for efterspørgselsberegningen.

3.1 Udledning af vægten

På træningsdata sættes $A_i = B_i + \mu_i^{\text{raw}}$ og $H_i = H_{w(i),m(i)}$ med niveau $L = 1$. For hvert lead minimeres

$$\min_{0 \leq w \leq 1} \sum_i (H_i + w(A_i - H_i) - Y_i)^2. \quad (10)$$

Differentiering med hensyn til w giver

$$w_\ell = \text{clip}_{[0,1]} \left(\frac{\sum_i (A_i - H_i)(Y_i - H_i)}{\sum_i (A_i - H_i)^2} \right). \quad (11)$$

Hvis nævneren er for lille, gemmes ingen vægt for det lead. Koden bruger den nærmeste gemte vægt eller 1 uden krympningsmodel.

3.2 Fordelingen efter krympning

Den krympede skala multipliceres med den samme empiriske form:

$$D = \mu_{t,\ell}Z, \quad S_D(x) = S_Z(x/\mu_{t,\ell}), \quad x > 0, \mu_{t,\ell} > 0. \quad (12)$$

Ved $\mu = 0$ sættes halen til nul for positive tærskler. Negative formkvantiler kan stadig forekomme, men prisberegningen tæller kun positive salgsgrenser.

Præcis fortolkning. Krympningen skalerer fordelingen; den blander ikke to fulde prognosefordelinger. μ er heller ikke nødvendigvis præcis $\mathbb{E}[D]$: den poolede kvantilform er ikke tvunget til at have middelværdi 1. Desuden tillader (9) ikke negativ forventet resterende pickup, selv om træningsdata kan indeholde negativ pickup. Modellen er derfor ikke en fuld stokastisk model for annulleringer og frigivelse af allerede solgt kapacitet.

Eksempel. Med $B = 20$, $\mu^{\text{raw}} = 12$, $H = 24$, $L = 1$ og $w = 0,4$ bliver $\hat{Y} = 0,4 \cdot 32 + 0,6 \cdot 24 = 27,2$ og $\mu = 7,2$. Kalenderen dæmper dermed pickup-skalaen fra 12 til 7,2.

4 Priselasticitet og forventet salg

Ved pris p_k skaleres efterspørgslen med

$$g_k = \left(\frac{p_k}{p_0}\right)^{-\varepsilon}, \quad D_k = g_k D, \quad S_{D_k}(x) = S_D(x/g_k). \quad (13)$$

De konfigurerede elasticiteter er 1,6 for rum og 2,0 for senge. De er *antagelser*, ikke målte kausale effekter på egne gæster. Eksempelvis giver 10 % højere værelsespris $g = 1,1^{-1,6} \approx 0,859$.

4.1 Hvorfor summeres halerne?

For ikke-negativ heltallig efterspørgsel X og heltallig kapacitet C gælder

$$\min(X, C) = \sum_{j=1}^C \mathbf{1}\{X \geq j\}, \quad (14)$$

$$\mathbb{E}[\min(X, C)] = \sum_{j=1}^C \mathbb{P}(X \geq j). \quad (15)$$

Koden evaluerer derfor

$$Q_k(C) = \sum_{j=1}^C S_D(j/g_k), \quad V_k(C) = ((1-c)p_k - v)Q_k(C). \quad (16)$$

For en kontinuert D_k svarer summen til at tælle hele positive enheder, dvs. $X_k = \lfloor \max(D_k, 0) \rfloor$, hvis halen var en konsistent fordeling. Den kontinuerte forventning ville i stedet være integralet $\int_0^C S_{D_k}(x) dx$. `expected_sales` afrunder kapaciteten op med en numerisk tolerance og begrænser som standard summen til 400 enheder.

4.2 Et gennemregnet prisvalg

Et rent regneeksempel: $C = 3$, $c = 0,16$, $v = 95$ kr. Tabellen antager de viste halesandsynligheder ved hvert trin; de er ikke en prognose for hostellet.

p_k	$S_k(1)$	$S_k(2)$	$S_k(3)$	Q_k	$(1-c)p_k - v$	V_k
600	0,95	0,80	0,55	2,30	409	940,70
700	0,90	0,70	0,40	2,00	493	986,00
800	0,80	0,55	0,25	1,60	577	923,20

700 kr. vinder: højere bidrag pr. salg opvejer tabet af volumen fra 600 kr., men ikke det yderligere volumetab ved 800 kr.

Uden kapacitetsbinding giver den kontinuerte approksimation $V(p) \propto ((1-c)p - v)p^{-\varepsilon}$. For $\varepsilon > 1$ har den optimum

$$p^* = \frac{\varepsilon v}{(\varepsilon - 1)(1 - c)}. \quad (17)$$

Med rumparametrene fås ca. 302 kr. Det illustrerer, hvorfor en antaget høj elasticitet kan presse priser ned: indtil måling begrænses det rå trinvalg til højst ét trin under reference. Dette er en politikbegrænsning, ikke et estimat.

5 Bid price: værdien af den sidste enhed

Ved fast pris og bidrag $n = (1 - c)p - v \geq 0$ er værdien af kapacitet C $V(C) = n \sum_{j=1}^C S_D(j/g)$. Den marginale værdi er derfor

$$b(C) = V(C) - V(C - 1) = n S_D(C/g). \quad (18)$$

Bid price er den forventede alternativomkostning ved at afgive den sidste ledige enhed. I eksemplet med 700 kr. er $b(3) = 493 \cdot 0,40 = 197,20$ kr. Koden bruger $\max(0, n)$ og returnerer dette bidrag ved $C \leq 0$ som en konvention; den konvention er ikke en tilladelse til overbooking.

5.1 Flex-rum

Lad f være antal flex-rum allokeret til private, og lad et flex-rum rumme h senge. Kapaciteterne bliver $C_r(f) = C_r(0) + f$ og $C_b(f) = C_b(0) - hf$. Ved faste priser og efterspørgselsmodeller er gevinsten ved ét ekstra privat rum

$$G(f) = n_r S_r((C_r(f) + 1)/g_r), \quad (19)$$

$$T(f) = n_b \sum_{j=0}^{h-1} S_b((C_b(f) - j)/g_b), \quad (20)$$

$$\Delta(f) = G(f) - T(f). \quad (21)$$

Flytningen foretages, når $\Delta(f) > \tau$, hvor $\tau = 25$ kr. i konfigurationen. Her er $h = 8$; det tidligere lagerekssempel i referencen bruger 4 og er ikke den aktuelle parameter.

Algoritmen starter ved den tilladte nedre grænse og lægger rum til, indtil gevinsten er for lille eller øvre grænse nås. For monotone haler falder rumgevinsten, mens tabet på de fjernede senge stiger. Derfor er den grådige regel begrundet for dette separable problem. Den numeriske ekstremhale omtalt på side 2 betyder, at monotonicitet ikke er en ubetinget garanti i koden.

Trinvalget beregnes i motoren med hvert lagers *maksimalt mulige* kapacitet. Begge lagre kan ikke samtidig få alle flex-rum. Prisvalg og flex-allokering er derfor ikke én fælles global optimering. Rumtyper, faktiske reservationer og ophold på tværs af datoer begrænser desuden allokeringen.

5.2 Ophold over flere nætter

For ét ophold over datoerne $\mathcal{T}$ er den implementerede kapacitetsværdi

$$B_{\text{ophold}} = \sum_{t \in \mathcal{T}} b_t(C_t). \quad (22)$$

Et tilbuds samlede bidrag kan sammenlignes med denne sum. Funktionen `stay_value` findes, men er ikke koblet til bookingmotoren. Summen alene løser ikke sammenhængende rumtildeling eller automatisk minimumsophold.

6 Grupper: forventet fortrængning og punktprognose

Hvis en gruppe bruger $q \leq C$ enheder på en dato, er den marginale fortrængningsværdi ved fast pris

$$A(q) = V(C) - V(C - q) = \sum_{i=0}^{q-1} b(C - i). \quad (23)$$

De første enheder kan koste lidt, mens de sidste koster meget. Med eksempellets 700 kr. koster to enheder $493(0,40 + 0,70) = 542,30$ kr. i mistet forventet dækningsbidrag.

Motorens konkrete gruppegulv er mere konservativt. I `engine.py` anvendes $\tilde{n}_t = (1 - c)p_t$ i fortrængningssummen: der fratrækkes ikke variable omkostninger på det fortrængte salg. Derefter lægges gruppens variable omkostning til:

$$\tilde{A}_t(q) = (1 - c)p_t \sum_{i=0}^{q-1} S_t((C_t - i)/g_t), \quad (24)$$

$$r_{t,\min} = v + \frac{\tilde{A}_t(q)}{q}. \quad (25)$$

Med to rum i eksemplet giver dette $v + 588 \cdot 1,10/2 = 418,40$ kr. pr. rum, før prisgrænser og afrunding. Et gulv baseret på mistet dækningsbidrag ville i stedet være $95 + 542,30/2 = 366,15$ kr.

Som standard sættes $g_t = 1$ i gruppeberegningen, så længe elasticiteten ikke er målt. Den særskilte hjælpefunktion `group_floor` kan gennemsnitsberegne over flere nætter med de nettopriser, den får; motorens viste tilbud beregnes pr. dato med (25). Der indgår ingen særskilt division med $1 - c_{\text{gruppe}}$ for en eventuel provision på gruppetilbuddet.

6.1 Det supplerende punktbaserede tal

Motoren viser også `minimum_rate_certain`. Med total rumkapacitet K_t og punktprognose $\hat{F}_t$ er beregningen

$$r_{t,\text{punkt}} = v + \frac{(1 - c)p_t}{q} \max\{0, q - \max(0, K_t - \hat{F}_t)\}. \quad (26)$$

Navnet “certain” betyder her en beregning, der tager punktprognosen som udfald. Det er hverken en øvre fraktil, et worst case eller en garanti. Begge tal underlægges prisgulv, prisloft og afrunding.

7 Adaptivt efterspørgselsniveau

Forventet og faktisk pickup summeres først på tværs af datoer til E og A . Den implementerede opdatering, når $E \geq 20$, er

$$L_{\text{ny}} = \text{clip}_{[0,6,1,6]} \left[L_{\text{gammel}} \left(\frac{\max(0, A) + 1}{E + 1} \right)^{0,07} \right]. \quad (27)$$

Ved $E < 20$ ændres niveauet ikke. Tillægget 1 undgår nulstilling ved nul pickup. For $L = 1$, $E = 100$ og $A = 75$ fås ca. 0,980: en lille korrektion. Rum og senge har separate niveauer. Dette er en adaptiv regel, ikke en ny estimation af elasticiteten eller hele fordelingen.

8 Fra økonomisk optimum til endelig pris

De aktuelle trinfaktorer er

$$(0,80; 0,86; 0,93; 1,00; 1,07; 1,15; 1,24; 1,35; 1,48).$$

De multipliceres med dagens grundpris og behandles med prisgrænser og afrunding. Ved ens målværdi vælger `choose_rung` det første trin.

Efter den indledende rabatbegrænsning justeres trinpositionen med markedet:

$$u = k_{\text{begrænset}} + \frac{w_M}{s} \text{clip}_{[-1,1]} \left(\frac{p_{\text{comp}} I_{\text{kvalitet}} / p_{\text{base}} - 1}{a_M} \right). \quad (28)$$

Her er $w_M = 0,20$, $s = 0,15$ og $a_M = 0,20$. Uden markedspris er markedsleddet nul. Mere end tre dage før ankomst udglattes positionen med forrige position, når den findes: $\bar{u} = 0,5u + 0,5u_{\text{før}}$. Derefter tilføjes eventtrin $\text{round}(\max(0, F_{\text{event}} - 1)/0,10)$.

Hysteresis kræver normalt en afstand på mindst 0,75 trin før skift. Der tillades højst to trin op og ét ned pr. trinbeslutning; tæt på ankomst to ned. Desuden gælder bl.a. eventgulv, langtidsgrænse, manuelle låse, prisingulv, prisloft og en daglig ændringsbremse på 15 % med fast 24-timers anker. V3's særskilte knaphedsgulv og ratchet er slået fra ved aktiv v4.

Eksploration i koden. Et deterministisk hashvalg pr. dato og lager kan vælge et nabotrin ved lead højst 60 dage, hvis afstanden mellem positionen og det valgte trin er højst 0,35. Dette tester ikke direkte, om to trins forventede dækningsbidrag er næsten ens. Referencens beskrivelse af "lige gode trin" er derfor en hensigt, ikke en verificeret økonomisk betingelse. En kausal elasticitetsmåling kræver også et korrekt forsøgsdesign og logning af de priser, gæsterne faktisk blev eksponeret for.

9 Hvad kan valideres?

Prognosepræcision kan måles på senere, adskilte historiske perioder med fx. $\text{MAE} = N^{-1} \sum_t |Y_t - \hat{Y}_t|$ og empirisk dækning af prognoseintervaller. Gentagne lead-observationer fra samme dato er afhængige; derfor bør usikkerhed beregnes med datoen som klynge. Referencens historiske resultater er ikke genkørt som del af dette dokument.

En bedre salgsprognose dokumenterer ikke en omsætningsgevinst ved andre priser. Historiske priser afhænger selv af forventet efterspørgsel. Modellen rummer også andre antagelser end elasticiteten: censurering, sæsonstruktur, formpooling, haleapproximation og driftsregler påvirker beslutningen.

Kildegrundlag og reproduktion. Projektets `REFERENCE.md` samt `app/cube.py`, `app/demand.py`, `app/bidprice.py`, `app/engine.py`, `app/ladder.py`, `app/level.py` og `config/config.yaml`. Ved forskel mellem forklarende tekst og kode beskriver notatet koden. Alle regneeksempler er illustrative. LaTeX-kilden kompiles med `pdflatex v4-matematik.tex` (to kørsler).